Rancangan Penyimpanan Aplikasi Taksi

Praktikum Big Data 4 - Studi Kasus P | Alfaris Aulia Rahman | 2411533006

Sumber run: sintetis K-1b (seed 42). Dataset 1,000,000 baris; K-2/K-3 menggunakan sampel 300,000, TinyDB 20.000 awal. K-6 memakai 200.000 titik sintetis. Benchmark berasal dari notebook tugas pada Colab.

1. Pilihan untuk lima fitur

Fitur dan pilihan	Alasan / angka benchmark	Kelemahan
1. Detail perjalanan berdasarkan ID Key-value; SQLite berindeks sebagai alternatif	200 ID: KV 0.0011 s, SQLite berindeks 0.0048 s. Kunci langsung melayani satu perjalanan; untuk field opsional, nilai dapat berupa dokumen JSON.	Dict/TinyDB praktikum berada di memori dan bukan server produksi; ID sampel harus diganti ID stabil, dengan persistensi dan sinkronisasi.
2. Dashboard pendapatan per wilayah per jam DuckDB + Parquet berpartisi; Delta untuk data otoritatif	Agregasi 1,000,000 baris: DuckDB 0.0319 s, SQLite 0.6151 s. Column pruning dan filter partisi mengurangi I/O; tanggal/jam dapat menjadi dimensi agregasi.	Benchmark K-4 merangkum wilayah, bukan seluruh query dashboard. Partisi tanggal perlu dirancang; banyak file kecil dan pembaruan proyeksi dapat menambah biaya.
3. Tujuan populer dan rute dua/tiga langkah Graph berarah berbobot arus antar zona	Dua langkah: graph 0.0173 s vs SQL 0.0055 s; hasil sama 91 zona. Graph memudahkan traversal k dan ranking bobot arus.	Graph agregat kehilangan detail trip/waktu dan belum berarti rute jalan fisik. Kecepatan tidak selalu unggul; arus sintetis tidak membuktikan pola taksi nyata.
4. Taksi yang menjemput dalam radius 500 m Indeks spasial STRtree plus pemeriksaan jarak tepat	K-6, 1.000 kotak: query STRtree 0.2964 s vs NumPy 0.5554 s; bangun 0.0754 s. Indeks menyaring kandidat lokasi sebelum predicate/jarak tepat.	Ini benchmark kotak pada titik sintetis, bukan radius 500 m. Perlu koordinat dan ID taksi nyata, CRS meter/jarak geodesik, lalu DISTINCT ID taksi.
5. Audit/kembalikan tarif ke tanggal 1 Delta Lake: versi, time travel, restore	K-7: v0 100,000 baris, v1/v2 150,000; koreksi 2,517 menaikkan total 2517.00. Append asing ditolak tanpa komit.	Versi harus dipetakan ke cutoff tanggal dan akses koreksi dibatasi. File historis memakan ruang; VACUUM terlalu dini menghilangkan kemampuan membaca versi lama.

Angka adalah pengukuran pada satu proses, bukan perbandingan Redis, MongoDB, Neo4j, atau sistem terdistribusi. Dataset perjalanan sintetis, bila dipakai, hanya menguji cara menyimpan dan bertanya.

Aliran Data dan Konsistensi Salinan

2. Diagram rancangan

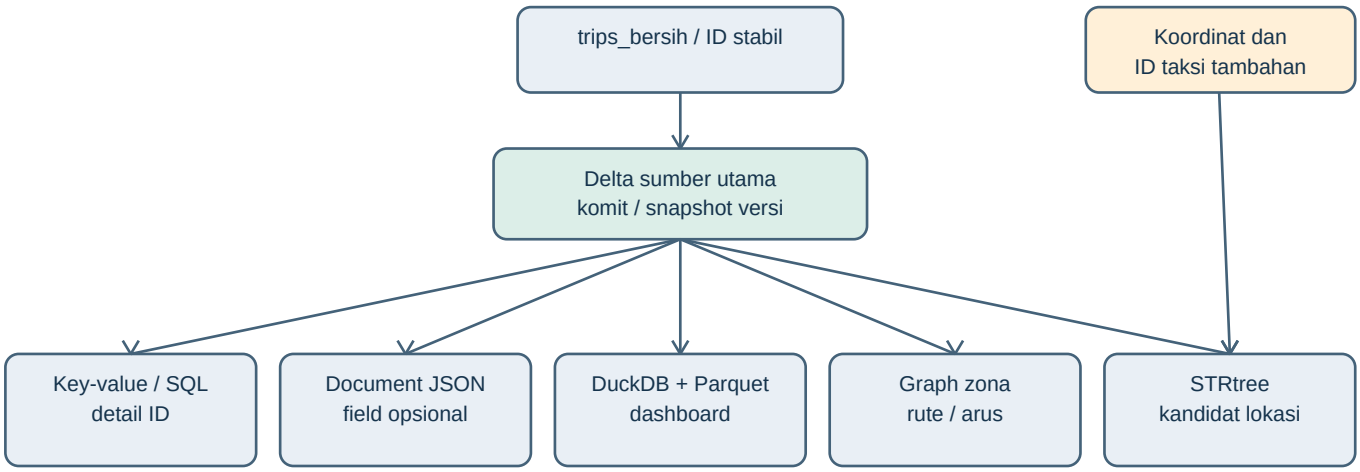

Proyeksi ber-ID dan source_version; checkpoint setelah batch selesai

Audit: cutoff tanggal -> nomor versi -> time travel / RESTORE

Aliran di atas adalah rancangan produksi: Delta menyimpan snapshot otoritatif, sementara proyeksi melayani pola query masing-masing. Percobaan modul membangun model langsung dari trips_bersih; tidak mengimplementasikan pipeline sinkronisasi terdistribusi.

3. Data ganda dan cara menjaga kesamaan

Data ganda muncul pada detail key-value/document, tabel analitik, edge graph, dan indeks spasial. Delta dirancang sebagai sumber utama terversi; tiap proyeksi menyimpan source_version dan ID perjalanan stabil. Perubahan komit diproses melalui batch/change log dengan upsert idempoten, lalu checkpoint versi dipublikasikan setelah proyeksi selesai. Rekonsiliasi memeriksa jumlah/kunci/agregat terhadap snapshot sumber. Detail pembayaran dan audit membaca snapshot otoritatif; dashboard/rekomendasi boleh tertinggal sesuai SLA dan menampilkan versi/waktu pembaruan. Embedding wilayah memerlukan pembaruan salinan ketika referensi zona berubah. Desain ini belum diimplementasikan sebagai sistem terdistribusi dalam praktikum. ID praktikum dibuat pada sampel; ID produksi harus ditetapkan dan dipersistenkan sebelum semua proyeksi dibentuk.

4. Radius, identitas, dan waktu

Pencarian 500 meter membutuhkan koordinat jemput dan ID taksi yang tidak disediakan oleh percobaan ini. Bounding box/STRtree menyaring kandidat; jarak geodesik atau proyeksi dalam meter memastikan radius tepat. Hasil kemudian dihubungkan ke ID taksi dan dideduplikasi. Waktu K-6 hanya mendukung manfaat indeks pada query kotak, bukan SLA radius.

Tanggal 1 untuk audit harus didefinisikan sebagai cutoff waktu/zona waktu dan dipetakan ke nomor versi Delta yang dicatat. Time travel membaca versi lama; restore menerbitkan keadaan versi itu sebagai komit baru sehingga riwayat tidak hilang. File historis harus dipertahankan selama periode audit.

Bukti dan Batas Interpretasi

5. Rekap bukti yang dipakai

Kebutuhan	Bukti	Interpretasi
Ambil satu data lewat id	200 ID: scan 6.8203s; indeks 0.0048s; KV 0.0011s	Indeks menghindari scan; rasio scan/indeks 1420.90x pada sampel yang sama.
Merangkum banyak baris	1,000,000 baris: DuckDB 0.0319s vs SQLite 0.6151s; 300,000 baris: SQL 0.2094s vs KV 1.4247s	Dua pasangan memakai populasi masing-masing yang sama; SQLite/DuckDB 19.28x, KV/SQL 6.80x.
Field opsional/berubah	20,001 dokumen; cuaca 1; tanpa tip 6,021	Field baru diterima tanpa migrasi; validasi aplikasi diperlukan agar salah nama/tipe tidak diam-diam diterima.
Keterhubungan k langkah	2 langkah: graph 0.0173s; SQL 0.0055s; hasil sama 91 zona; k=1..4 [83, 91, 91, 91]	Pemenang waktu run ini: SQL; graph dipilih karena k mudah diubah.
Lokasi dalam wilayah	1.000 kotak: NumPy 0.5554s; indeks 0.2964s; bangun 0.0754s	Rasio NumPy/query 1.87x; termasuk pembangunan 1.49x; hasil sama pada titik sintetis.
Perubahan aman dan kembali ke versi lama	v0/v1/v2 100,000/150,000/150,000; append asing ditolak; compact 21 -> 1 file	Log menyimpan riwayat komit; snapshot lama tetap terbaca, skema dijaga, dan compaction tidak mengubah jumlah baris.

6. Batas pengukuran

Rasio dibandingkan hanya pada pasangan dengan populasi sama: KV vs SQL memakai sampel, sedangkan DuckDB vs SQLite memakai seluruh dataset. Waktu muat dan pembangunan indeks dipisahkan. Eksperimen K mengukur satu run; cache, versi pustaka, dan mesin memengaruhi angka. Graph dipilih karena pertanyaan keterhubungan, meskipun SQL dapat lebih cepat pada run tertentu.

Dokumen fleksibel tetap memerlukan validasi aplikasi. ID sampel bukan ID taksi. Graph arus tidak sama dengan jaringan jalan fisik. Perbandingan kotak pada derajat tidak membuktikan akurasi radius meter, dan hasil data sintetis tidak mewakili pola perjalanan nyata.

Acuan: Modul Praktikum Big Data - 04, bagian K, O, P dan R; benchmark_nosql.csv serta rekap_model_nosql.csv yang dihasilkan oleh run notebook ini. Catatan transaksi aktual disertakan dalam arsip Delta.